

黛安娜 (Diana) AI Agent 開發與效能優化日誌

第一階段: 建置初期 (原型搭建與功能驗證)

- * 系統定位: 基於 LM Studio 本地 CPU 部署模型 (Gemma 4), 建立具備陪伴屬性的 Discord 角色 Bot。
- * 初期功能:
 - * 角色扮演 Prompt: 設定《PRAGMATA》黛安娜人設, 限制輸出客服套話。
 - * 基礎 RAG 長期記憶: 導入 ChromaDB 向量資料庫 (SentenceTransformer), 儲存並檢索過往歷史對話。
 - * JSON 短期記憶: 維護最近對話視窗 (memory.json), 提供連貫對話能力。
- * 初期痛點與性能瓶頸:
 - * 檢索污染與失憶: 硬性事實 (如主人喜好) 與閒聊廢話混在 RAG 中, 容易檢索失敗或產生幻覺。
 - * 回應嚴重延遲與斷線: 同步 API 呼叫鎖死 Discord 主線程, 常出現 heartbeat blocked for more than 70~90 seconds 警告並導致 Bot 斷線。
 - * 人設崩壞: 模型經常吐出文青抽象修辭 (如「身體裡有星星」) 與氾濫的 Emoji, 完全不像 8~10 歲小孩。
 - * 推理時間過長: 開頭啟用 Reasoning 思考無長度限制 (Unrestricted), 單句生成耗時高達 5 分鐘。

第二階段: 架構重構與功能模組化

- * 記憶三層架構解耦:
 - * 靜態 Profile (user_profile.json): 存放硬性事實與喜好, 100% 注入 System Prompt, 並升級 /profile_delete <編號> 精準管理。
 - * 動態 RAG (ChromaDB): 僅在出現「記得、上次」等記憶關鍵字時觸發, 避免無謂運算與雜訊干擾。
 - * 短期記憶滑窗 (memory.json): 維持最近對話脈絡。
- * 重構重置機制:
 - * /reset: 僅清空短期 JSON 記憶。
 - * /deepreset: 完全格式化短期記憶與 ChromaDB 向量庫。
- * 獨立 Persona 檔案 (character_persona.json):
 - * 將年齡 (8~10 歲)、去文青腔、去客服敬語、嚴禁堆疊 Emoji 與 Few-shot 對話範例獨立抽離, 方便隨時微調人設。
- * 功能擴充:
 - * 多模態視覺 (Vision): 支援 Discord 傳圖, 轉換 Base64 供 Gemma 4 辨識互動。
 - * 定時提醒 (/remind): 使用背景 Loop Task, 時間到達自動在頻道提醒。
 - * 斜線指令 (Slash Commands): 重構為 commands.Bot 與 @bot.tree.command, 原生同步 Discord 選單。

第三階段: 效能與非同步 (Async) 深度優化

- * 全管線非同步化(解決 Discord 卡死):
 - * 引進 AsyncOpenAI: 將所有 OpenAI API 呼叫非同步化(await), 解決主線程阻塞與 Heartbeat 超時問題。
 - * 線程與 I/O 背景化: 使用 asyncio.to_thread 將 ChromaDB 向量查詢隔離; 將 JSON 硬碟寫入(save_json_async)丟至背景執行。
- * 好感度與記憶整理架構翻修:
 - * 取消每句即時評分: 避免連續對話時頻繁發起多餘的背景 API 請求造成卡頓。
 - * 2 小時閒置歸檔機制: 當超過 2 小時無對話, 背景自動呼叫 LLM 結合角色性格進行「全段好感度綜合評估 + 對話重點摘要歸檔至 RAG」, 完成後完全清空短期記憶, 還原乾淨 Context。
 - * 每週記憶提煉: 每週日凌晨自動將 RAG 舊碎片歸納為長效 Profile。

第四階段: 思考深度控制與 CPU 推理極限壓榨

- * 限制推理思考長度(Reasoning Budget):
 - * 在即時對話 API 中帶入 extra_body={"max_thinking_tokens": 256}, 將日常對話的思考時間壓縮至 2 秒內, 同時保留歸檔任務充足的思考空間。
- * 模型降級與 CPU 推理優化:
 - * 模型切換: 將推理模型從較大的 E4 切換為更輕量的 E2, 顯著降低 CPU 負擔。
 - * 純 CPU 推理極限: 在完全使用 CPU + DDR4 記憶體(頻寬約 40~50 GB/s)的受限硬體條件下, 成功擺脫原先 5 分鐘的漫長等待。
- * 優化成果:
 - * 單句回應總延遲從最初的 5 分鐘(300 秒) 逐步降至 2~3 分鐘, 最終在純 CPU 運算下成功壓進 1 分鐘以內!

第一~四階段系統架構總覽

- * 對話驅動: AsyncOpenAI + LM Studio(純 CPU 運行 Gemma 4 E2)+ 輕量思考上限限制 (256 Tokens)
 - * 人設控制: character_persona.json(8~10歲童音 + Few-shot 範例學習 + 嚴格去文青腔)
 - * 記憶體系:
 - * 系統級: 靜態 Profile(定時提煉)
 - * 情境級: 動態 RAG(條件觸發)
 - * 對話級: 短期記憶(2小時閒置自動摘要歸檔並清空)
 - * 互動介面: Discord 原生斜線指令(Slash Commands)+ 多模態圖片辨識
-

第五階段: 多頻道併發穩定性、模型切換體驗與人設真實感深化

- * 併發穩定性: JSON 檔案讀寫加鎖
 - * 問題根源: memory.json/favorability.json 原本是「整包讀取→修改→整包寫回」, 多頻道同時

對話時，較慢的頻道存檔會用舊資料覆蓋掉其他頻道剛寫入的新資料，造成短期記憶或好感度悄悄遺失。

- * 解法：新增 per-file 的 `asyncio.Lock(get_file_lock)`，並拆成兩段鎖：使用者訊息先鎖存一次，等 LLM 回應完成後再重新讀最新版本、鎖存第二次。刻意不把整個 LLM 生成過程包進鎖裡，避免一個頻道在等模型回應時卡住其他頻道的存檔。

- * 好感度更新同步改為 `update_favorability_async`，走同一套鎖機制。

- * 短期記憶瘦身：圖片不再長期佔用 Context

- * 問題根源：Discord 傳圖後，完整 base64 圖片會整包存進 `memory.json`，之後每一輪對話都要重新把舊圖片塞回 prompt，在純 CPU 推理下拖慢速度、也讓記憶檔案越滾越肥。

- * 解法：拆成「當輪送給模型的版本」（含完整圖片，只用一次）與「存進短期記憶的版本」（圖片轉為純文字標記，如「（傳送了一張圖片）...」），歷史對話只保留文字，不重複佔用推理資源。

- * `/switch` 指令模型選單化

- * 問題根源：切換模型需要手動輸入完整模型名稱，容易打錯或不確定 LM Studio 目前實際載入哪些模型。

- * 解法：加入 Discord Autocomplete (`model_name_autocomplete`)，打字時即時查詢 LM Studio `client.models.list()`，直接用選單點選目前可用模型；LM Studio 未啟動或查詢失敗時靜默回傳空清單，不讓指令噴錯。

- * 修正程式碼細節缺陷

- * `extra_body={"max_thinking_tokens": 256}` 附近的 Tab/Space 混用縮排統一為空白，避免潛在解析風險。

- * 確認 Gemma 4 全系列原生支援可設定的思考模式（含 E2B），先前誤判為「無效參數」的說法已訂正。

- * 人設真實感優化（角色卡查證重寫）

- * 查證來源：Capcom 官方訪談與 Wiki 資料，確認《人機迷網／虛實萬象》黛安娜的角色設計理念——開發團隊內部設有「黛安娜警察」審查小組，明確要求配音與行為方向是「講話像真的小孩」，而不是「表演得很可愛」；她的個性設定也內建「透過接觸新事物觸發情感學習」的成長機制。

- * `character_persona.json` 重構為 `personality_traits`／`speech_patterns`／`tone_rules` 三層，並對齊 `build_system_prompt` 原有的「個性特質」「說話節奏」欄位：

- * 新增最高原則：嚴禁刻意賣萌討好的句子，寧可平淡自然也不要浮誇甜膩。

- * 補上真實小孩常見特徵：話題跳躍、常問「為什麼」、遇到不懂的事會表現出真的不懂，而非用大人邏輯裝懂分析。

- * 好感度反應加入「相處學習」的成長感描述，避免每次都套同一套固定撒嬌公式。

- * 新增 3 則 few-shot 範例，補強跳題、裝不懂、連續發問等真實童言童語感，與原本偏撒嬌向範例互補。

- * `bot.py` 內建的備援預設人設同步更新，避免 `character_persona.json` 遺失時退回舊版設定。

 目前系統架構總覽（更新）

- * 對話驅動：AsyncOpenAI + LM Studio（純 CPU 運行 Gemma 4 E2B）+ 輕量思考上限限制（256

Tokens, 確認為原生支援功能)

* 併發安全: memory.json / favorability.json per-file asyncio.Lock, 圖片僅存於當輪 prompt、不落地長期記憶

* 人設控制: character_persona.json (8~10歲童音 + 個性特質 / 說話節奏分層 + 去文青腔 + 「像真小孩不表演可愛」最高原則)

* 操作體驗: /switch 支援 LM Studio 模型清單即時 Autocomplete

* 互動介面: Discord 原生斜線指令 (Slash Commands) + 多模態圖片辨識 (歷史記憶不重複帶入圖片本體)